Siamská neuronová síť (optimalizace velikosti)

Bc. Samuel Kiszka

27. května 2026

Úvod

- Představení problému
- Návrh řešení
- Definice experimentů
- Výsledky
- Zhodnocení

Úloha

- Generování embeddingů / klasifikace tříd
- Výstupy kombinačních obvodů
- Obrázky 256 $\times$ 256
- 30 tříd, 15–30 vzorků na třídu

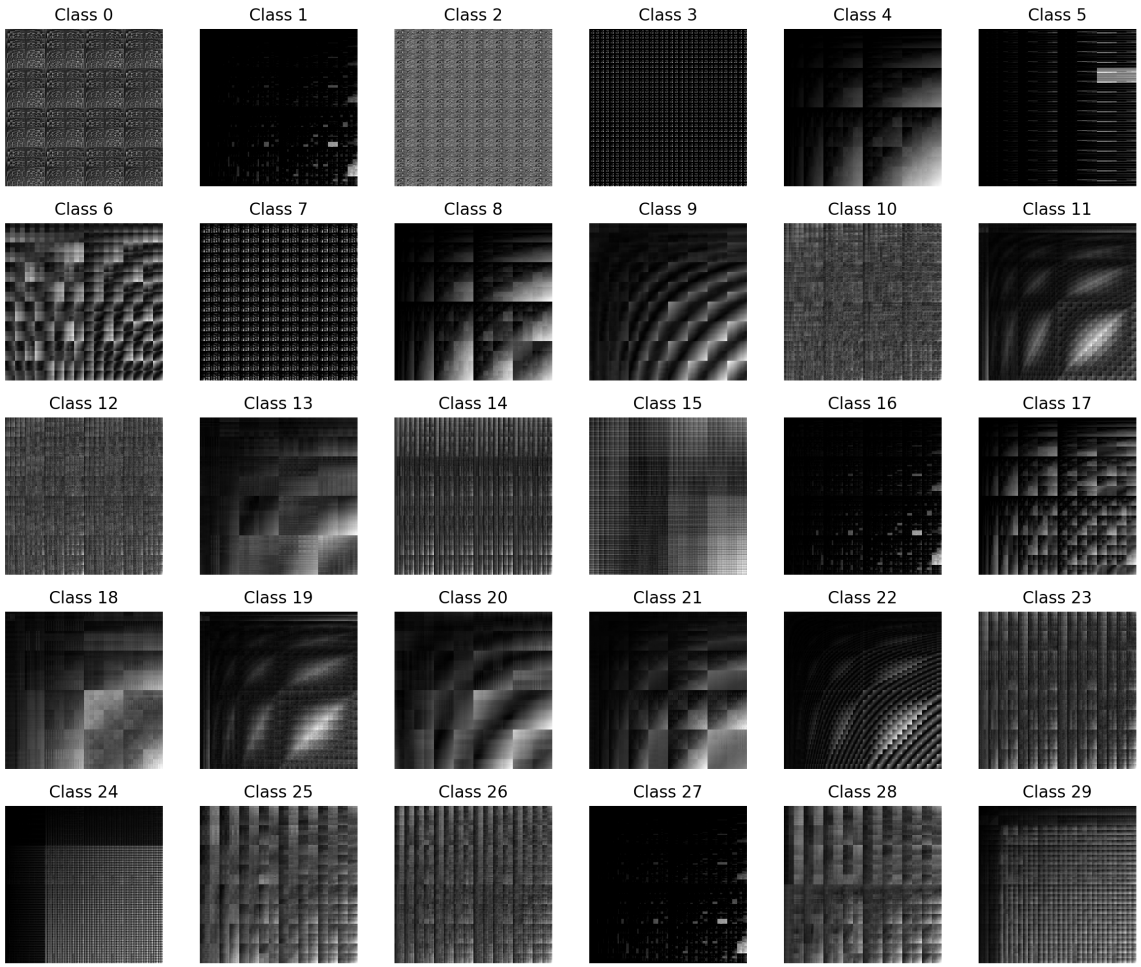

Řešení

- Kontrastivní učení
- StratifiedKFold validace
- Náhodně generované páry (1/1)
- Konvoluční modely
- Testovací úloha: stejná vs. jiná třída

Model	**Embedding**	**MACs**	**Počet parametrů**
VGGEmbedNet1	32	302.6M	699.4K
VGGEmbedNet3	32	47.3M	20.9K
VGGEmbedNet6	32	113.2K	5.9K
VGGEmbedNet8	32	7.6K	624
VGGEmbedNet13	4	168	28

Experimenty

15 běhů pro každý model v každém experimentu, 30 epoch
evaluační metrika - ROC-AUC

1. Porovnání modelů
   - 1000 párů na epochu
   - modely dle tabulky výše
2. Vliv velikosti embeddingu
   - 1000 párů na epochu
   - dimenze embeddingu: 4, 16, 32, 64
   - modely: VGGEmbedNet(1, 6, 13)
3. Potřebný počet párů pro trénování
   - embedding 32
   - počet párů na epochu: 1000, 500, 100, 32
   - modely: VGGEmbedNet(1, 6, 13)

Výsledky - Porovnání modelů

- Každý větší model je statisticky významně lepší než všechny menší.
  - jednostranný Mann–Whitney test ($\alpha = 0.05$)
  - nejvyšší p-hodnota: $p = 0.03095$ (VGG3 vs VGG1)
- Výpočetní náročnost (relativně k největšímu modelu):
  - $1 \rightarrow 6.4 \rightarrow 2.7 \times 10^3 \rightarrow 4.0 \times 10^4 \rightarrow 1.8 \times 10^6$

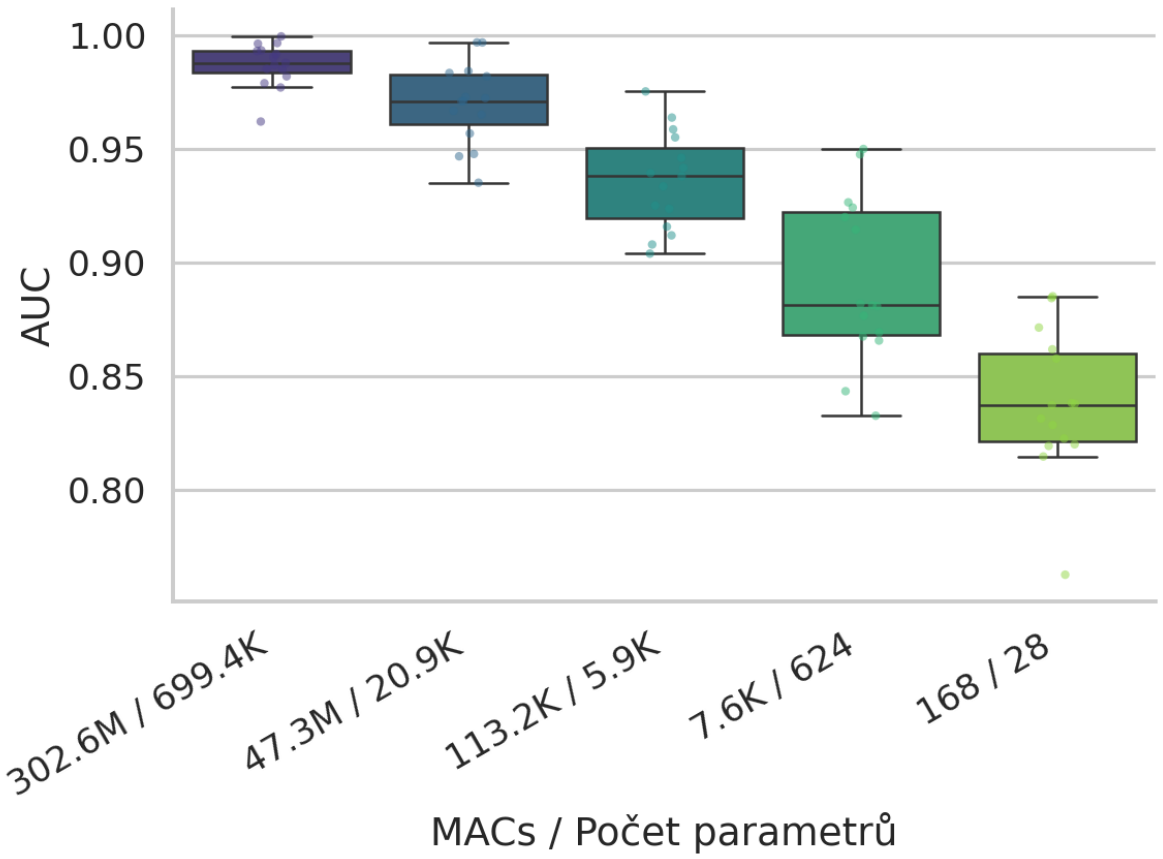

Výsledky - Porovnání modelů

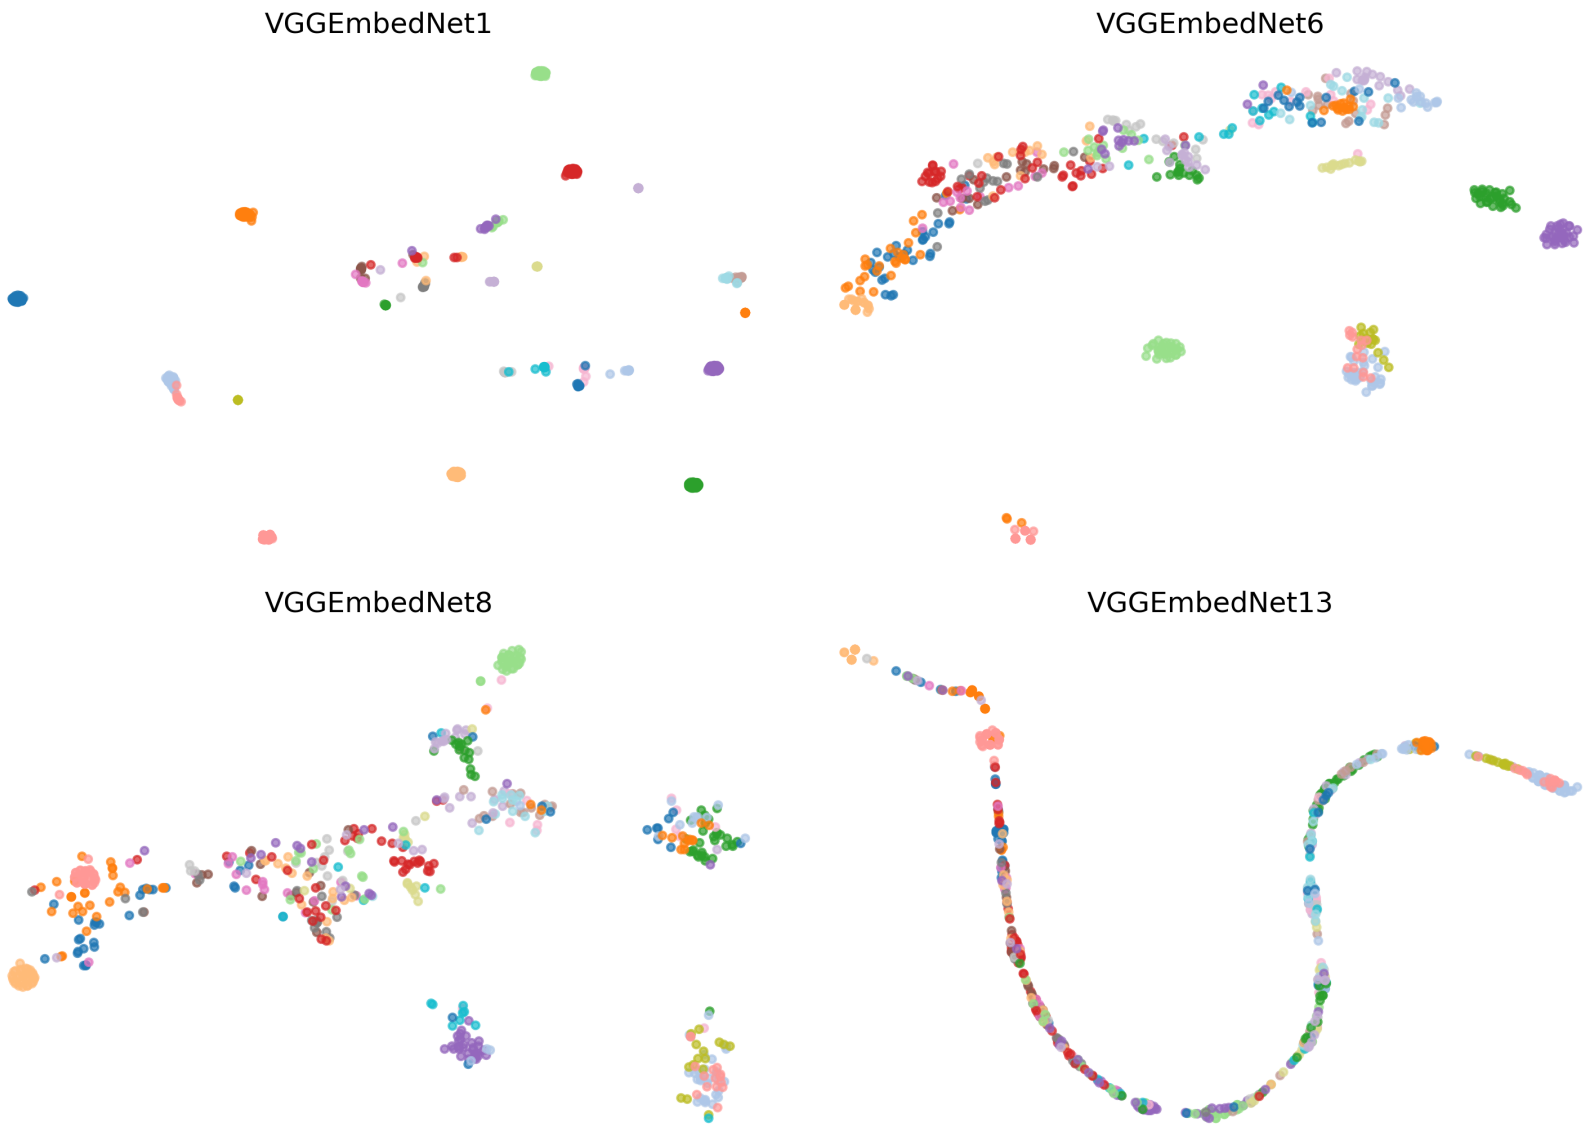

Výsledky - Vliv velikosti embeddingu

- Vliv velikosti embeddingu není statisticky významný.
  - Kruskal–Wallis test ($\alpha = 0.05$)
  - nejnižší $p = 0.3806$

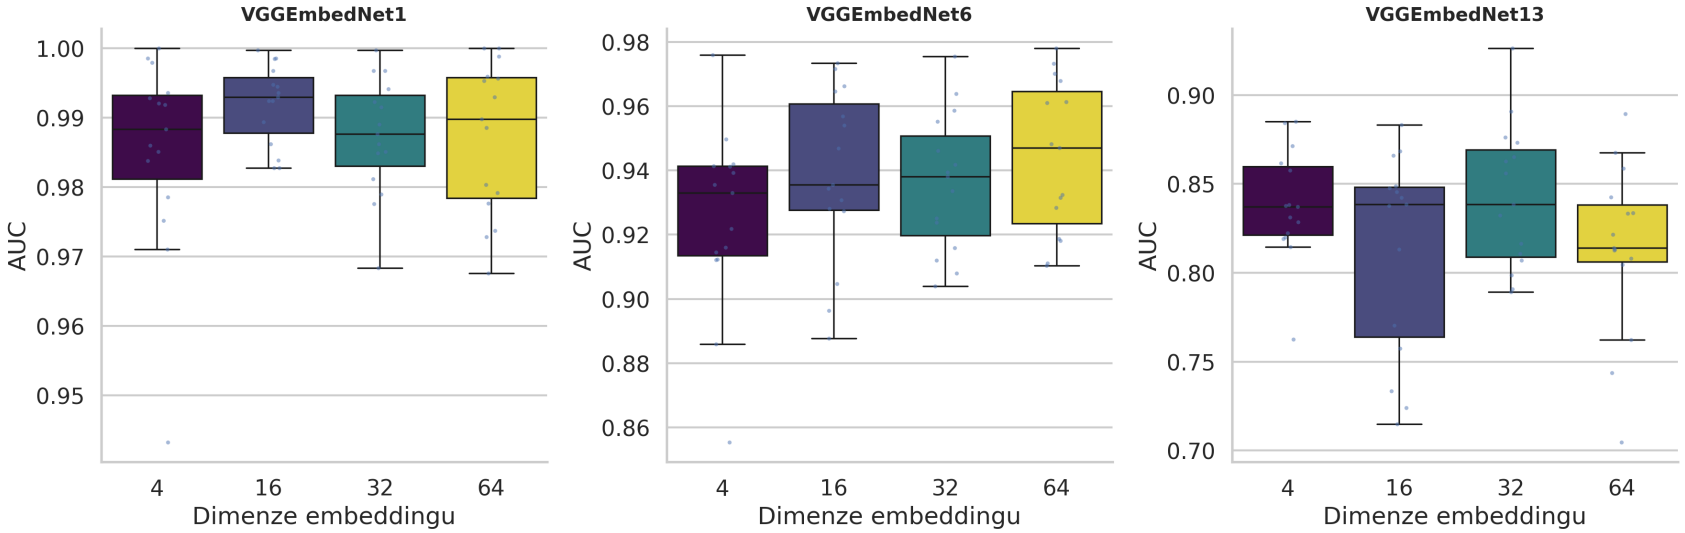

Výsledky - Velikost trénovacích dat

- Vliv počtu trénovacích párů na epochu nemá globální statistický význam, ale není zanedbatelný.
  - Kruskal–Wallis test ($\alpha = 0.05$)
  - VGGEmbNet1 - 32 $<$ 500, 1000
  - VGGEmbNet6 - 32 $<$ 500, 1000, 100 $<$ 1000
  - VGGEmbNet13 - nemá vliv

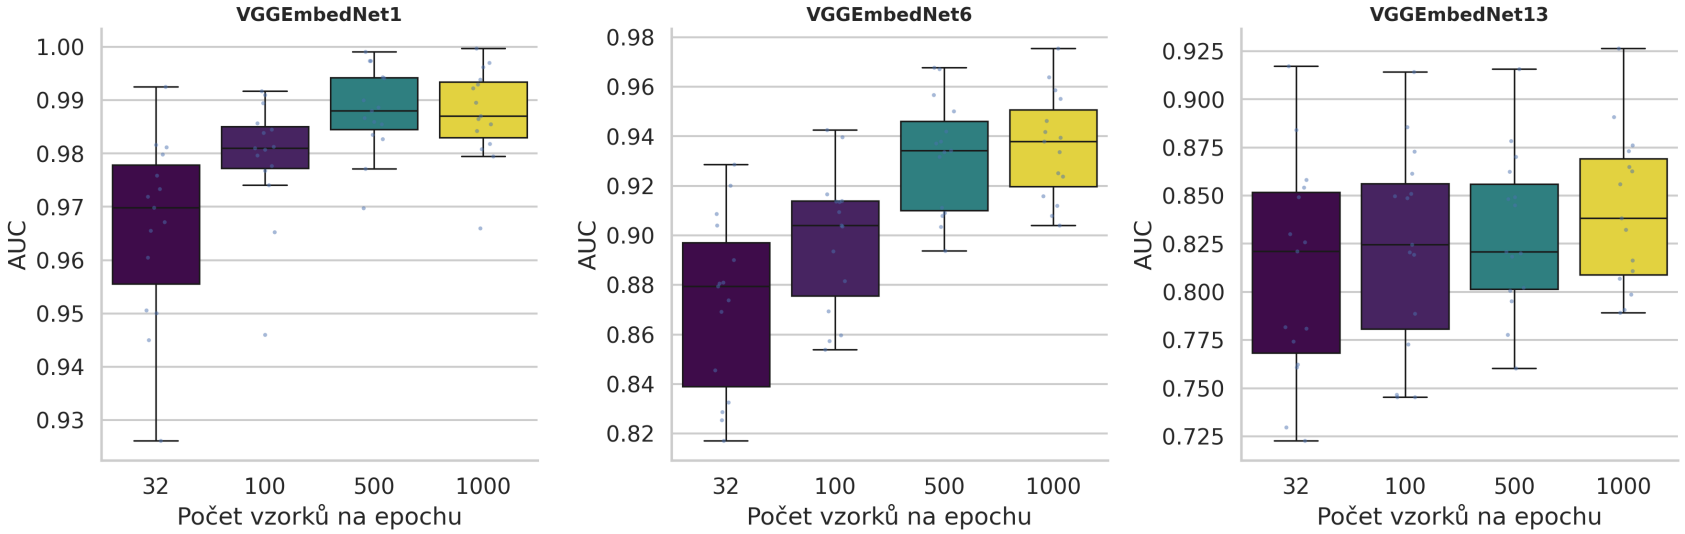

Zhodnocení

- dobré výsledky i s miniaturním modelem
  - jednoduše separovatelná data
  - vliv evaluační úlohy
- velikost modelu má vliv na přesnost
- žádný model nedominuje jiné
- velikost embeddingu výsledky příliš neovlivňuje
- větší modely dokáží využít většího množství trénovacích dat lépe
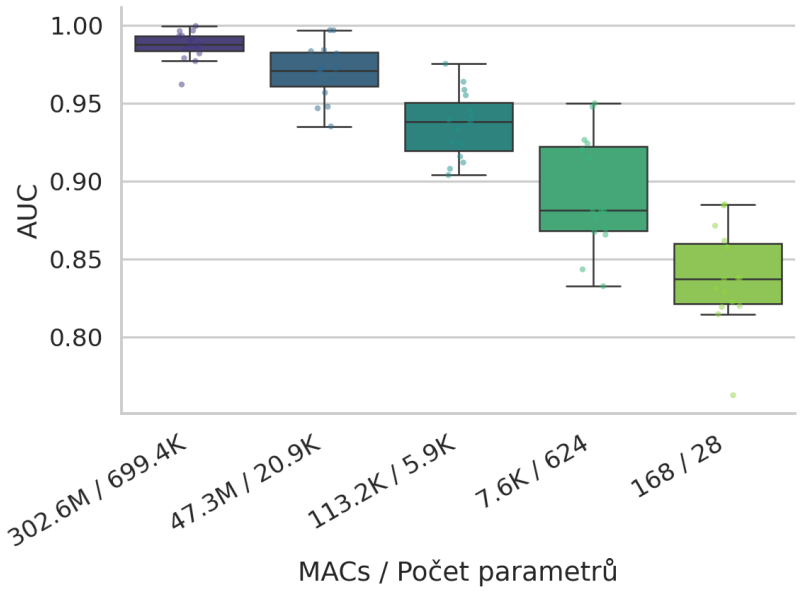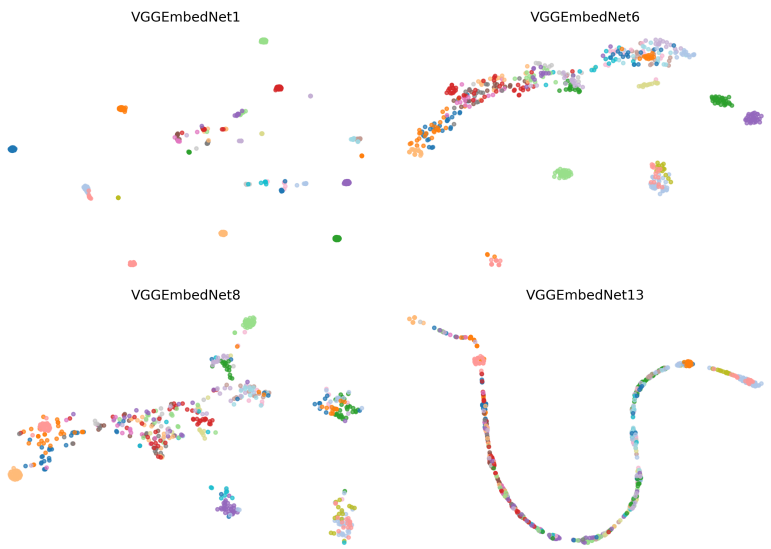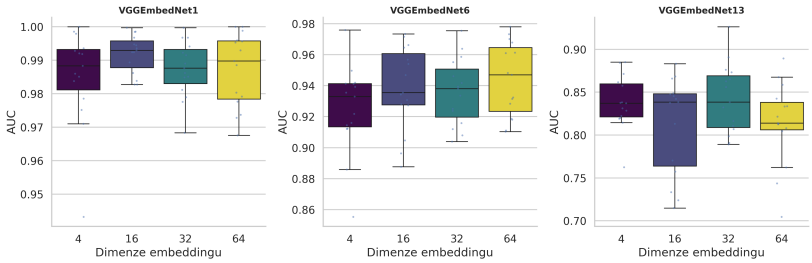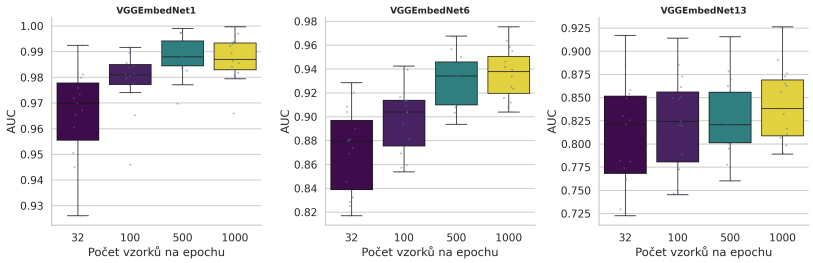
Děkuji za pozornost!